

✓ 03.1_Division_TrainValTest

Objetivo

Cargar el dataset limpio de la encuesta NFCS 2021, explorar rápidamente su estructura, derivar algunas variables básicas y dividir el conjunto de datos en particiones estratificadas de entrenamiento, validación y prueba para su posterior modelado.

Entradas (Inputs)

- `data/processed/final/NFCS_2021_final_clean.csv`

Salidas (Outputs)

- `data/splits/final/X_train.parquet`
- `data/splits/final/y_train.parquet`
- `data/splits/final/X_val.parquet`
- `data/splits/final/y_val.parquet`
- `data/splits/final/X_test.parquet`
- `data/splits/final/y_test.parquet`

[+ Código](#)[+ Texto](#)

Resumen Ejecutivo

- El notebook aborda la preparación de los datos limpios de la encuesta NFCS 2021 para un proyecto de modelado de riesgo financiero.
- Se importa el dataset desde Google Drive y se definen las librerías clave (pandas, NumPy, scikit-learn, pyarrow).
- Se crea la variable **FL_SCORE** (suma de aciertos en preguntas de alfabetización financiera) y una métrica de **PORTFOLIO_DIVERSITY**.
- Se especifican las columnas de identificación (`NFCSID`), el objetivo (`B10`) y el peso de muestreo (`WGT1`).
- Se construye la matriz de características **X** y el vector objetivo **y**, eliminando IDs y columnas no predictivas.
- Se realiza una división estratificada en tres conjuntos: entrenamiento ($\approx 70\%$), validación ($\approx 15\%$) y test ($\approx 15\%$) usando `train_test_split`.
- Los tamaños resultantes son **X_train** (1976×92), **X_val** (424×92) y **X_test** (392×92), manteniendo la distribución de la variable objetivo.
- Finalmente, se guardan los tres "splits" en formato Parquet mediante **pyarrow** para facilitar su carga en etapas posteriores.

✓ 1. Carga de dependencias y montaje de Google Drive

Agrupar e importar todas las librerías necesarias (estándar, terceros y locales) y montar Google Drive para acceder a los datos.

```
import sys
from pathlib import Path

from google.colab import drive
import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split

# Configuración de semilla para reproducibilidad
RANDOM_STATE = 42

# Montar Google Drive
drive.mount('/content/drive', force_remount=True)

# Añadir la raíz del proyecto al path para poder importar 'config'
ROOT_PATH_STR = '/content/drive/MyDrive/TFM-AntonioEsquinas'
if ROOT_PATH_STR not in sys.path:
    sys.path.append(ROOT_PATH_STR)

# Importar las rutas necesarias desde el archivo de configuración
# Se importa la ruta del dataset procesado final y la de los splits finales.
from config import FINAL_PROCESSED_DATA_DIR, FINAL_SPLITS_DIR, METADATA_DIR

# Definir la ruta del archivo de entrada usando las variables de config
DATA_FILE_PATH = FINAL_PROCESSED_DATA_DIR / 'NFCS_2021_final_clean.csv'

# Leer el dataset
df = pd.read_csv(DATA_FILE_PATH)
print(f" Dataset cargado con {df.shape[0]} filas y {df.shape[1]} columnas")

print('\n Primeras filas del dataset:')
display(df.head())

print('\n Información general:')
display(df.info())

print('\n Estadísticas descriptivas:')
display(df.describe())

# Conteo de valores nulos
TARGET = 'B10' # Asegúrate de que esta es tu variable objetivo
na_pct_full = df.isna().mean().sort_values(ascending=False)
print('\n Top 10 variables con más % de NA:')
display(na_pct_full.head(10))

# Distribución de la variable objetivo
```

```
if TARGET in df.columns:
    print(f"\n Distribución de la variable objetivo '{TARGET}':")
    display(df[TARGET].value_counts(normalize=True))
else:
    print(f"\n La columna {TARGET} no existe en el dataset.")
```



Mounted at /content/drive

✅ Módulo de configuración cargado y estructura de carpetas asegurada.
Dataset cargado con 2824 filas y 92 columnas

Primeras filas del dataset:

	NFCSID	A1	A2	A3	B2_1	B2_2	B2_3	B2_4	B2_5	B2_20	...	G12	G13	H31
0	2.021010e+09	1.0	1.0	1.0	1.0	2.0	1.0	2.0	2.0	1.0	...	2.0	3.0	1.0
1	2.021010e+09	1.0	1.0	1.0	1.0	2.0	1.0	2.0	2.0	1.0	...	3.0	3.0	1.0
2	2.021010e+09	1.0	1.0	1.0	1.0	1.0	1.0	2.0	2.0	2.0	...	2.0	4.0	2.0
3	2.021010e+09	2.0	2.0	1.0	2.0	2.0	1.0	2.0	2.0	2.0	...	2.0	3.0	2.0
4	2.021010e+09	1.0	1.0	1.0	1.0	2.0	1.0	2.0	2.0	2.0	...	3.0	2.0	2.0

5 rows × 92 columns

Información general:

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 2824 entries, 0 to 2823

Data columns (total 92 columns):

#	Column	Non-Null Count	Dtype
0	NFCSID	2824 non-null	float64
1	A1	2824 non-null	float64
2	A2	2824 non-null	float64
3	A3	2824 non-null	float64
4	B2_1	2824 non-null	float64
5	B2_2	2824 non-null	float64
6	B2_3	2824 non-null	float64
7	B2_4	2824 non-null	float64
8	B2_5	2824 non-null	float64
9	B2_20	2824 non-null	float64
10	B2_23	2824 non-null	float64
11	B2_24	2824 non-null	float64
12	B30	2824 non-null	float64
13	B31	2824 non-null	float64
14	B3	2824 non-null	float64
15	B32	2824 non-null	float64
16	B4	2824 non-null	float64
17	B10	2824 non-null	float64
18	B11	2824 non-null	float64
19	B35	2824 non-null	float64
20	B23	2824 non-null	float64
21	B24	2824 non-null	float64
22	B25	2824 non-null	float64
23	B26	2824 non-null	float64
24	C22_1	2824 non-null	float64
25	C22_2	2824 non-null	float64
26	C22_3	2824 non-null	float64
27	C22_4	2824 non-null	float64
28	C24	2824 non-null	float64
29	C25	2824 non-null	float64
30	C26	2824 non-null	float64
31	C30	2824 non-null	float64
32	C7	2824 non-null	float64
33	D1_1	2824 non-null	float64
34	D1_2	2824 non-null	float64
35	D2	2824 non-null	float64

El resultado muestra la distribución de la variable `proportion` en el DataFrame inicial, donde la clase 3.0 representa el 54.99 % de los datos, seguida de la clase 2.0 con el 27.34 %, la clase 4.0 con el 9.56 % y la clase 1.0 con el 8.11 %. Este desbalance de clases es clave a la hora de estratificar los datos o aplicar técnicas de balanceo para evitar sesgos en el modelo.

2. Definición de la variable FL_SCORE

Definir nombre de la variable que almacenará la puntuación de alfabetización financiera.

```
# FL_SCORE = suma de aciertos en preguntas de alfabetización financiera
literacy_items = ['G4', 'G5', 'G6', 'G7', 'G8', 'G11', 'G12', 'G13', 'G21']
literacy_present = [col for col in literacy_items if col in df.columns]
if literacy_present:
    df['FL_SCORE'] = df[literacy_present].sum(axis=1)
    print("Variable FL_SCORE creada correctamente.")
else:
    print("Atención: Ninguno de los literacy_items está en df. No se creó FL_SCORE.")

# PORTFOLIO_DIVERSITY = número de activos marcados (B2_)
asset_cols = [c for c in df.columns if c.startswith('B2_')]
if asset_cols:
    df['PORTFOLIO_DIVERSITY'] = (df[asset_cols] == 1).sum(axis=1)
    print("Variable PORTFOLIO_DIVERSITY creada correctamente.")
else:
    print("Atención: No se encontraron columnas B2_*. No se creó PORTFOLIO_DIVERSITY.")

# TRADER_SCORE = inversamente proporcional a B3 + ajuste por B31
if 'B3' in df.columns and 'B31' in df.columns:
    B3_norm = df['B3'].replace({98: np.nan, 99: np.nan})
    df['TRADER_SCORE'] = (5 - B3_norm).add(df['B31'].map({1:1, 2:0}), fill_value=0)
    print("Variable TRADER_SCORE creada correctamente.")
else:
    print("Atención: Las columnas B3 y/o B31 no existen. No se creó TRADER_SCORE.")

# **Verificamos que efectivamente se hayan agregado** las nuevas columnas a df
print("Columnas actuales de df:")
print(df.columns.tolist())
print("Total columnas en df:", len(df.columns))
print("Dimensiones tras derivar variables:", df.shape)

# Verificamos que efectivamente se hayan agregado las nuevas columnas a df
print(df.columns.tolist())
print("Total columnas en df:", len(df.columns))
print("Dimensiones tras derivar variables:", df.shape)

df.dtypes
df.memory_usage(deep=True)
df.info()
```

3. Definir variables de identificación

Estadísticas descriptivas:

	NFCSID	A1	A2	A3	B2_1	B2_2
Crea la lista ID_24B con las 24 columnas que se usarán como identificadores	2824	0.000000	2824	0.000000	2824	0.000000

```
ID_VARS = ['NFCSID']
TARGET = 'B10'
WEIGHT_VARS = ['WGT1'] # Puedes quitar si no usas pesos

# Verificar que TARGET existe
if TARGET not in df.columns:
    raise ValueError(f"La columna TARGET '{TARGET}' no se encuentra en el dataset.")
```

	75%	2.021027e+09	2.000000	1.000000	1.0	1.000000	2.000000	2.00
1.000000	2.000000	2.000000	2.000000	2.000000	2.000000	2.000000	2.000000	2.00

4. Construcción de la matriz de características (X) y vector objetivo (y)

8 rows x 92 columns

Top 10 variables con más % de NA:
 Elimina de df las columnas de identificación, objetivo y pesos; añade variables derivadas si existen; define y; y muestra las columnas resultantes de X.

	NFCSID	0.0
0.0	0.0	0.0

```
# Construir X partiendo de df: quitamos ID, TARGET, WEIGHT_VARS
X = df.drop(columns=ID_VARS + [TARGET] + WEIGHT_VARS, errors='ignore')
```

```
# Forzar que las derivadas estén en X (si existen en df)
derived_vars = ['FL_SCORE', 'PORTFOLIO_DIVERSITY', 'TRADER_SCORE']
for v in derived_vars:
    if v in df.columns and v not in X.columns:
        X[v] = df[v]
```

```
# Definir y
y = df[TARGET]
```

```
# Verificar
print("\n Mostrar columnas del df para verificar:")
print(X.columns.tolist())
print("Total columnas en X:", len(X.columns))
print("Shape de X:", X.shape)
print("Shape de y:", y.shape)
```

proportion

Mostrar columnas del df para verificar:

	1.0	0.549929
['A1', 'A2', 'A3', 'B2_1', 'B2_2', 'B2_3', 'B2_4', 'B2_5', 'B2_20', 'B2_23', 'B2_24', 'B2_25', 'B2_26', 'B2_27', 'B2_28', 'B2_29', 'B2_30', 'B2_31', 'B2_32', 'B2_33', 'B2_34', 'B2_35', 'B2_36', 'B2_37', 'B2_38', 'B2_39', 'B2_40', 'B2_41', 'B2_42', 'B2_43', 'B2_44', 'B2_45', 'B2_46', 'B2_47', 'B2_48', 'B2_49', 'B2_50', 'B2_51', 'B2_52', 'B2_53', 'B2_54', 'B2_55', 'B2_56', 'B2_57', 'B2_58', 'B2_59', 'B2_60', 'B2_61', 'B2_62', 'B2_63', 'B2_64', 'B2_65', 'B2_66', 'B2_67', 'B2_68', 'B2_69', 'B2_70', 'B2_71', 'B2_72', 'B2_73', 'B2_74', 'B2_75', 'B2_76', 'B2_77', 'B2_78', 'B2_79', 'B2_80', 'B2_81', 'B2_82', 'B2_83', 'B2_84', 'B2_85', 'B2_86', 'B2_87', 'B2_88', 'B2_89', 'B2_90', 'B2_91', 'B2_92']	0.549929	0.549929
Total columnas en X:	92	92
Shape de X:	(2824, 92)	(2824, 92)
Shape de y:	(2824,)	(2824,)

5. División estratificada de los datos

dtype: float64

Realiza una división estratificada en tres pasos: extrae primero el conjunto de prueba (15%), luego el de validación (~15%), y mantiene el restante como entrenamiento; finalmente muestra las formas de cada subconjunto

```
# División estratificada en Train / Validation / Test

# Primer split: 15% test
X_temp, X_test, y_temp, y_test = train_test_split(
    X, y, test_size=0.15, stratify=y, random_state=RANDOM_STATE
)
# Segundo split: ~15% validación
X_train, X_val, y_train, y_val = train_test_split(
    X_temp, y_temp, test_size=0.1765, stratify=y_temp, random_state=RANDOM_STATE
)

print(" Shapes resultantes:")
print(f"    • X_train: {X_train.shape}, y_train: {y_train.shape}")
print(f"    • X_val:   {X_val.shape},   y_val:   {y_val.shape}")
print(f"    • X_test:  {X_test.shape},   y_test:  {y_test.shape}")
```

```
⇒ Shapes resultantes:
    • X_train: (1976, 92), y_train: (1976,)
    • X_val:   (424, 92),   y_val:   (424,)
    • X_test:  (424, 92),   y_test:  (424,)
```

✓ 6. Instalación de pyarrow y guardado de los splits en formato Parquet

Se asegura de que pyarrow esté instalado y guarda X_train, y_train, X_val, y_val, X_test y y_test en archivos Parquet en la ruta configurada, confirmando al final la operación.

```
# Guardado de splits (VERSIÓN FINAL)

# Asegurarse de que la librería para Parquet esté instalada
!pip install pyarrow -q

# Guardar splits en Drive usando la ruta FINAL desde config.py
X_train.to_parquet(FINAL_SPLITS_DIR / 'X_train.parquet')
y_train.to_frame().to_parquet(FINAL_SPLITS_DIR / 'y_train.parquet')

X_val.to_parquet(FINAL_SPLITS_DIR / 'X_val.parquet')
```